

ANALISIS MULTIVARIAT

QUIZ 4

ASTHAGINA DELIA P

1. Apa perbedaan mendasar antara Cluster Analysis dan Discriminant Analysis?

Cluster Analysis (analisis klaster) adalah metode *unsupervised* yang mencari struktur alami dalam data tanpa menggunakan label. Tujuannya hanya menemukan grup-grup yang mirip satu sama lain. Discriminant Analysis, khususnya Linear Discriminant Analysis (LDA), adalah metode *supervised* yang menggunakan data berlabel untuk membangun aturan klasifikasi yang memetakan predictor X ke kelas G .

2. Apa fungsi prior probability dalam classification?

- Menentukan prevalensi awal tiap kelas sebelum melihat data fitur X ; misalnya kelas yang lebih umum mendapat prior yang lebih tinggi.
- Memengaruhi batas keputusan pada model berbasis Bayes (mis. LDA) karena log-prior $\log(\pi_k)$ ditambahkan ke fungsi diskriminan, sehingga kelas dengan prior besar “dipilih” lebih mudah.
- Membantu mengatasi ketidakseimbangan kelas bila data latih tidak seimbang, memberikan bobot yang lebih realistis pada kelas minoritas.

3. Dalam LDA, mengapa decision boundary dapat menjadi linear?

- LDA mengasumsikan bahwa semua kelas memiliki distribusi normal multivariat dengan kovarians yang sama (Σ). Karena Σ konstan, suku kuadratik pada log-likelihood saling meniadakan.
- Setelah menyederhanakan log-posterior, fungsi diskriminan menjadi

$$\delta_k(x) = x^T \Sigma^{-1} \mu_k - \frac{1}{2} \mu_k^T \Sigma^{-1} \mu_k + \log \pi_k,$$

yang merupakan fungsi linear terhadap x . Batas keputusan antara dua kelas k dan j didapat dari $\delta_k(x) = \delta_j(x)$, menghasilkan persamaan linear (garis untuk 2-dimensi, bidang untuk dimensi lebih tinggi).

4. Sebuah observasi mempunyai discriminant scores — Class A = 1.7, Class B = 3.4, Class C = 2.1. Masuk class mana? Jelaskan.

Observasi tersebut ditempatkan ke Class B, karena skornya (3.4) adalah yang tertinggi di antara ketiga kelas.

- Pada LDA, aturan keputusan memilih kelas dengan nilai discriminant terbanyak ($\hat{G}(x) = \arg \max_k \delta_k(x)$).
- Nilai $\delta_B = 3.4 > \delta_C = 2.1 > \delta_A = 1.7$, jadi kelas B dipilih.
- Ini berarti model memperkirakan bahwa observasi tersebut paling mirip dengan distribusi (mean & covariance) kelas B.

5. Apa hubungan Mahalanobis Distance dengan Linear Discriminant Analysis?

Linear Discriminant Analysis menilai suatu observasi dengan membandingkan jarak Mahalanobis ke masing-mata mean kelas karena semua kelas mengasumsikan kovarians yang sama (Σ), suku kuadratik pada log-likelihood meniadakan dan keputusan menjadi “pilih kelas dengan jarak Mahalanobis terkecil” (atau skor diskriminan terbesar) terutama bila priornya sama.

6. Confusion matrix menghasilkan 70 observasi benar dan 10 observasi salah. Hitung: (a) Accuracy, (b) Misclassification Rate.

Jumlah total observasi = 70 benar + 10 salah = 80.

- $\text{Accuracy} = \frac{70}{80} = 0.875 \sim 87.5 \%$.
- $\text{Misclassification Rate} = \frac{10}{80} = 0.125 \sim 12.5 \%$.