


TUGAS ANALISIS MULTIVARIAT

PCA, Analisis Faktor, dan K-Means Clustering

Dataset Breast Cancer Wisconsin

Dipresentasikan Oleh:

Asthagina Delia Putri
20244920001



Dataset & Tujuan Analisis

Dataset yang digunakan dalam analisis ini adalah Breast Cancer Wisconsin (Diagnostic) yang dimuat melalui pustaka scikit-learn.

569

observasi

30

variabel numerik

2

kelas diagnosis

Unit observasi

Satu sampel tumor payudara (satu pasien). Nilai dihitung dari citra digital aspirasi jarum halus (FNA).
Diagnosis: 357 benign, 212 malignant.

Tujuan

- PCA: meringkas 30 variabel menjadi sedikit komponen
- Analisis Faktor: menemukan konstruk laten di balik variabel
- K-Means: mengelompokkan sampel yang serupa
- Label diagnosis tidak dipakai model, hanya untuk validasi

Arti variabel: 10 karakteristik inti sel

Radius

rata-rata jarak pusat ke tepi inti sel

Perimeter

keliling inti sel

Smoothness

variasi lokal panjang radius (kehalusan tepi)

Concavity

tingkat cekungan pada kontur

Symmetry

simetri bentuk inti sel

Texture

variasi nilai skala abu-abu citra

Area

luas inti sel

Compactness

$\text{perimeter}^2 / \text{area} - 1$ (kepadatan bentuk)

Concave points

jumlah bagian kontur yang cekung

Fractal dimension

kekasaran tepi ("coastline" $- 1$)

Data Preprocessing

0

Missing value

Tidak ada sel kosong dari 17.070 sel data (569×30). Tidak perlu imputasi atau penghapusan baris.

$\approx 232.000\times$

Selisih skala variabel

Rata-rata worst area 880,6 (SD 569,4) vs fractal dimension error 0,0038 (SD 0,0026). Skala sangat tidak seragam.

z-score

Standardisasi

$z = (x - \mu) / \sigma$, sehingga setiap variabel bermean 0 dan SD 1. Dipakai sama untuk PCA, FA, dan K-Means.

Standardisasi diperlukan karena:

PCA

berbasis varians: tanpa standardisasi, variabel area (skala ratusan) mendominasi komponen

K-Means

berbasis jarak Euclidean: variabel berskala besar menentukan jarak antar sampel

Analisis Faktor

bertumpu pada matriks korelasi, sehingga perlu skala setara agar loading sebanding

Hasil PCA: Varians & Jumlah Komponen



PC	Eigenvalue	Varians (%)	Kumulatif (%)
PC1	13,305	44,27	44,27
PC2	5,701	18,97	63,24
PC3	2,823	9,39	72,64
PC4	1,984	6,60	79,24
PC5	1,652	5,50	84,73
PC6	1,209	4,02	88,76

6 PC
Kaiser ($\lambda > 1$)


5 PC
Kumulatif $\geq 80\%$

6 PC
Dipakai

Keputusan: 6 PC dipertahankan (kriteria Kaiser). 30 variabel diringkas menjadi 6 dimensi dengan kehilangan informasi hanya 11,24%.


Interpretasi PCA: PC1 & PC2

Loading terbesar PC1 (44,27%)




PC1: ukuran & ketidakaturan tumor
Kontributor: concave points, concavity, compactness, perimeter/radius/area. Skor PC1 tinggi = tumor besar dengan kontur cekung dan tidak beraturan.

Loading terbesar PC2 (18,97%)



PC2: kekasaran tepi (fractal dimension)
Kontributor: fractal dimension (mean, error, worst). Variabel ukuran bermuatan negatif, jadi skor PC2 tinggi = tepi kompleks pada tumor yang relatif kecil.

Skor PC1 vs PC2 (menurut diagnosis)



Analisis Faktor: Kelayakan & Jumlah Faktor

0,832

KMO

Kategori baik ($> 0,5$). Data layak untuk Analisis Faktor.

$p < 0,001$

Uji Bartlett


$\chi^2 = 39.362$. Matriks korelasi bukan matriks identitas, ada korelasi antar variabel.

6 faktor

Kriteria Kaiser

Eigenvalue > 1 : 13,28 · 5,69 · 2,82 · 1,98 · 1,65 · 1,21.
Faktor ke-7 hanya 0,68.

Varians dijelaskan tiap faktor setelah rotasi varimax (%)



Metode

Ekstraksi minres, rotasi varimax (ortogonal), input data terstandarisasi.

Total 85,49%

varians dijelaskan oleh 6 faktor bersama.

Interpretasi Faktor

F1 · 34,0%

Ukuran tumor

mean area 0,97 · mean radius 0,96 ·
mean perimeter 0,96 · worst radius 0,95

Semua variabel radius, perimeter, dan area
(mean, worst, error) bermuatan > 0,8.

F2 · 18,1%

Variabilitas bentuk kontur

compactness error 0,90 · concavity
error 0,85 · fractal dim. error 0,82

Didominasi variabel error dari compactness,
concavity, dan fractal dimension.

F3 · 11,6%

Kehalusan permukaan

worst smoothness 0,92 · mean smoothness
0,81 · worst fractal dim. 0,57

Smoothness (mean dan worst) bermuatan
tertinggi, disusul fractal dimension.

F4 · 8,0%

Variabilitas tekstur & simetri

smoothness error 0,63 · texture error
0,62 · symmetry error 0,58

Hanya variabel error yang tinggi. Faktor
paling lemah, nama bersifat sementara.

F5 · 7,3%

Tekstur

worst texture 0,98 · mean texture
0,86

Hanya dua variabel texture yang
bermuatan tinggi, hampir murni satu dimensi.

F6 · 6,6%


Simetri

worst symmetry 0,91 · mean symmetry
0,61 · symmetry error 0,54


Semua variabel symmetry termuat pada
satu faktor yang sama.

K-Means: Memilih Jumlah Cluster

Elbow: inertia menurut K



Silhouette score menurut K



Prasyarat

Data distandardisasi (z-score) karena K-Means memakai jarak Euclidean.

Pengaturan


K = 2 sampai 10, n_init = 10, random_state = 42. Inertia dan silhouette dihitung per K.

Keputusan: K = 2

Silhouette tertinggi (0,343) dan inertia menurun landai tanpa siku tegas. K = 2 juga masuk akal secara substantif (dua diagnosis).

Profil Cluster (K = 2)

K-Means (K = 2) pada ruang PCI-PC2



375

Cluster 0 · 65,9%
339 benign (90,4%)

194

Cluster 1 · 34,1%
176 malignant (90,7%)

Rata-rata variabel	Cluster 0	Cluster 1	Rasio
mean radius	12,43	17,41	1,40×
mean area	486,8	979,9	2,01×
mean concavity	0,043	0,178	4,17×
mean concave points	0,026	0,093	3,55×
mean compactness	0,077	0,158	2,06×
worst area	596,5	1429,7	2,40×
texture error	1,205	1,239	1,03×

Cluster 1 = tumor lebih besar dengan kontur lebih cekung dan tidak beraturan. Tekstur hampir sama (rasio 1,03×).

Perbandingan PCA vs FA vs Cluster

Metode	Informasi yang diperoleh	Angka kunci
PCA	30 variabel diringkas menjadi 6 komponen. PC1 = ukuran & ketidakaturan tumor, PC2 = kekasaran tepi.	88,76% varians PC1 = 44,27%
Analisis Faktor	6 konstruk laten: ukuran, variabilitas kontur, kehalusan, variabilitas tekstur-simetri, tekstur, simetri.	85,49% varians KMO = 0,832
K-Means	2 kelompok sampel: kecil dengan kontur halus (375) vs besar dengan kontur tidak beraturan (194).	Silhouette 0,343 90,5% selaras diagnosis

Apakah interpretasi PCA & FA sama?

Searah, tetapi tidak identik. Keduanya menemukan dimensi ukuran, bentuk kontur, tekstur, dan simetri ($PC4 \approx F5$ tekstur). Bedanya, PC1 mencampur ukuran dengan bentuk, sedangkan FA setelah varimax memisahkannya menjadi F1 (ukuran) dan F2 (kontur). PCA menjelaskan varians total (88,76%), FA hanya varians bersama (85,49%).

Apakah cluster terlihat jelas di PC1-PC2?

Cukup jelas, bukan terpisah sempurna. Cluster terpisah terutama pada sumbu PC1 (rata-rata skor $-2,23$ vs $4,31$), tetapi ada tumpang tindih di sekitar PC1 0-2. Cluster 1 lebih menyebar dan memuat outlier. Silhouette 0,34 sejalan dengan tumpang tindih ini.

Key Insights

88,76%

informasi 30 variabel tersimpan dalam 6 PC

44,27%

varians dijelaskan PCI saja (ukuran & bentuk)

K = 2

jumlah kelompok alami sampel tumor

90,5%

kesesuaian cluster dengan diagnosis (ARI 0,65)

Metode paling memberi insight: PCA

1

Meringkas sekaligus menjelaskan 30 variabel yang sangat redundan (radius, perimeter, area) menjadi 6 dimensi, dan loading menunjukkan sumber variasinya.

2

Satu sumbu sudah memisahkan Skor PCI membedakan diagnosis (malignant 3,71 vs benign -2,21) dan kedua cluster K-Means (-2,23 vs 4,31).

3

Menjadi dasar metode lain Ruang PCI-PC2 dipakai untuk memvisualisasikan cluster. FA dan K-Means melengkapi: FA memberi nama konstruk, K-Means mengelompokkan sampel.

Limitations & Conclusion

Keterbatasan

- Multikolinearitas tinggi: variabel mean, error, dan worst saling tumpang tindih, sehingga F1 dominan dan F4 sulit dinamai.
- Kaiser ($\lambda > 1$) cenderung menghasilkan komponen/faktor berlebih. Varimax mengasumsikan faktor saling bebas.
- K-Means berasumsi cluster berbentuk bulat dan sensitif outlier. Silhouette 0,34 menunjukkan cluster tumpang tindih.
- PCA dan FA bersifat linear. Satu dataset (569 sampel), belum divalidasi pada data lain.
- Nama faktor dan cluster bersifat interpretasi sementara, bukan kesimpulan klinis.

Kesimpulan

- Data 30 variabel dapat diringkas menjadi 6 komponen (88,76% varians) tanpa kehilangan struktur utama.
- Struktur laten utama: ukuran, bentuk kontur, kehalusan, tekstur, dan simetri.
- Sampel membentuk 2 kelompok ($K = 2$) yang selaras 90,5% dengan diagnosis tanpa memakai label.